

Informe — Laboratorio 4, Parte 2

Modelos de aprendizaje automático para apoyar la detección de floraciones de cianobacteria

Laboratorio 4, Parte 2 — Análisis de Datos Geoespaciales Universidad del Valle de Guatemala (UVG) — CC3084 Data Science Fecha: 23 de agosto de 2026 Integrantes: Méndez Alvarado, Pablo José; Yee Vidal, María José.

Lagos de Atitlán y Amatitlán · 22 escenas Sentinel-2 L1C reales · 3,756,510 observaciones de agua · EPSG:32615 a 20 m (0.04 ha/píxel)

1. Problema y objetivos

Los lagos de Atitlán y Amatitlán presentan riesgo de floraciones de cianobacteria, un fenómeno ligado a exceso de nutrientes y condiciones ambientales favorables. El monitoreo de campo es costoso y de baja frecuencia, por lo que la Parte 1 de este laboratorio construyó un dataset de **3,756,510 observaciones por píxel** a partir de 22 escenas reales de Sentinel-2 (11 fechas por lago), calculando reflectancia, índices espectrales y una estimación de clorofila-a mediante el algoritmo CyanoLakes (NDCI). Esta Parte 2 usa ese dataset para:

1. Entrenar y comparar tres clasificadores binarios (Regresión Logística, Random Forest, XGBoost) que predicen si un píxel tiene clorofila-a alta.
 2. Evaluarlos con cuatro estrategias de validación —aleatoria, espacial, temporal y entre lagos— para medir qué tan bien generalizan más allá de los datos vistos.
 3. Interpretar el mejor modelo (importancia nativa, *permutation importance*, SHAP).
 4. Generar mapas de probabilidad y mapas de error espacial.
 5. Redactar conclusiones y limitaciones honestas sobre la utilidad real del sistema.
-

2. Datos: 22 escenas Sentinel-2 reales

Todas las cifras de este informe provienen de imágenes Sentinel-2 L1C descargadas de Copernicus Data Space para las 11 fechas oficiales de cada lago (22 combinaciones lago-fecha), procesadas a **20 m de resolución** en **EPSG:32615** (UTM 15N). El área por píxel es **0.04 ha** (20×20 m), derivada de la transformación afín real de cada ráster, no asumida.

No se usó ningún dato sintético en la construcción del dataset ni en el entrenamiento de esta Parte 2.

3. Preparación del dataset (Ejercicio 1)

Cada fila representa un píxel de agua válido (máscara WBI), con sus 9 bandas reflectancia (B02–B12), 5 índices espectrales (NDVI, NDWI, NDCI, FAI, clorofila-a), la fecha, el lago, las coordenadas y el bloque espacial de 1 km al que pertenece.

 Observaciones por lago y fecha

 Valores faltantes por variable

 Distribución de bandas e índices

Amatitlán aporta **399,646** observaciones y Atitlán **3,356,864** (Atitlán es un lago mucho más extenso). No hay valores faltantes en las variables usadas para el modelado.

4. Variable respuesta: umbral principal 8 µg/L y sensibilidad 20/25/50 (Ejercicio 2)

La respuesta binaria `high_cyano_8` marca clorofila-a estimada ≥ 8 µg/L, la **frontera** mesotrófico → eutrófico** de la clasificación trófica de la OECD (1982). Se eligió por su** significado ambiental, no por conveniencia estadística: de hecho es el umbral que **menos** favorece el balance de clases entre las cuatro opciones evaluadas.

Umbral	Positivos Amatitlán	% Amatitlán	Positivos Atitlán	% Atitlán
8 µg/L	57,996	14.51 %	2,150	0.064 %
20 µg/L	9,768	2.44 %	64	0.0019 %
25 µg/L	5,181	1.30 %	14	0.0004 %
50 µg/L	604	0.15 %	4	0.0001 %

Con 20, 25 o 50 µg/L, Atitlán queda con tan pocos positivos que ningún modelo podría aprender nada de esa clase en ese lago. El umbral de 8 µg/L es el único que deja una cantidad mínimamente razonable de positivos en ambos lagos, lo que hace viables la validación espacial y la generalización entre lagos de este informe. Los otros tres umbrales

quedan documentados como análisis de sensibilidad, no como alternativas de modelado en este ciclo.

5. Prevención de fuga de información (Ejercicio 3)

La respuesta se construye a partir de la cadena `B04, B05 → NDCI → clorofila-a → high_cyano_8`. Por lo tanto, **B04, B05, NDCI, clorofila-a, FAI (que comparte B04) y NDVI (que comparte B04)** están excluidos del conjunto de predictores**, junto con las variables de agrupación** (`lake`, `date`, `coordenadas`, `spatial_block_1km`) que permitirían memorizar la geografía o la fecha en vez de aprender la señal espectral.

Predictores principales (los únicos usados para entrenar): `B02, B03, B07, B08, B8A, B11, B12, NDWI`

El código incluye *asserts* que detienen la ejecución si alguna variable prohibida entra al conjunto `x`.

6. Modelos e hiperparámetros (Ejercicio 4)

Los tres modelos se ajustaron con `RandomizedSearchCV` (12 configuraciones × 3 folds, optimizando PR-AUC) sobre una muestra determinista de entrenamiento, semilla 42.

Modelo	Hiperparámetros seleccionados	PR-AUC en tuning
Regresión Logística	<code>l1_ratio=0.0</code> (equivalente a L2), <code>C=0.01</code>	0.9836
Random Forest	<code>min_samples_leaf=5</code> , <code>max_features='sqrt'</code> , <code>max_depth=None</code>	0.9962
XGBoost	<code>tree_method='hist'</code> , ajustado por <code>RandomizedSearchCV</code>	—

Nota técnica. `penalty` de scikit-learn quedó deprecado desde la versión 1.8; se migró a `l1_ratio` (0 = L2 pura, 1 = L1 pura), verificado numéricamente como equivalente exacto.

7. Validación aleatoria 70/30 (Ejercicio 5)

División estratificada por `high_cyano_8`, semilla 42, misma partición de prueba para los tres modelos.

Modelo	PR-AUC	Recall (umbral 0.5)	Precision (umbral 0.5)
Regresión Logística	0.9135	0.9947	0.4678
Random Forest	0.9814	0.9644	0.8550
XGBoost	0.9826	0.9885	0.7505

 Curvas ROC y Precision-Recall (aleatoria)

 Matrices de confusión (aleatoria)

 Comparativa de métricas (aleatoria)

Esta división es optimista: mezcla píxeles vecinos del mismo bloque de 1 km —casi idénticos espectralmente— entre entrenamiento y prueba. No debe leerse como la capacidad real del modelo de generalizar a zonas nuevas.

8. Validación espacial por bloques de 1 km (Ejercicio 6)

StratifiedGroupKFold con 5 folds sobre `spatial_block_1km` (EPSG:32615, cuadrícula de 1000 m): **ningún bloque aparece a la vez en entrenamiento y validación.**

 Asignación de bloques a folds espaciales

Modelo	PR-AUC medio	Desviación
Regresión Logística	0.9026	± 0.0563
Random Forest	0.9758	± 0.0128
XGBoost	0.9757	± 0.0150

Random Forest y XGBoost están en empate práctico: la diferencia (0.0001) es muchísimo menor que la desviación entre folds (0.0128–0.0150). Random Forest se selecciona por la regla determinista de mayor PR-AUC medio, **no por superioridad sustantiva.**

Validación temporal, ventana expansiva

Cada corte entrena únicamente con fechas anteriores y evalúa con la fecha siguiente (ambos lagos combinados cronológicamente), garantizando que ninguna observación futura entre al entrenamiento.

Modelo	PR-AUC medio	Desviación	Mínimo	Máximo
Regresión Logística	0.6429	± 0.2839	0.1323	0.9800
Random Forest	0.7416	± 0.2510	0.1307	0.9879
XGBoost	0.7042	± 0.2571	0.1842	0.9884

La caída frente a la validación espacial (de ~ 0.976 a ~ 0.74) y la desviación de ~ 0.25 muestran **inestabilidad temporal marcada**: el desempeño depende fuertemente de la fecha evaluada, señal de que la relación reflectancia $\leftrightarrow$ clorofila cambia con las condiciones atmosféricas y estacionales.

9. Generalización entre lagos (Ejercicio 7)

Se usó el modelo seleccionado por validación espacial (**Random Forest**), entrenando exclusivamente con un lago y evaluando en el otro, sin ajustar pesos ni umbral con el lago de prueba.

Experimento	Entrena	Evalúa	PR-AUC	Recall operacional	TP	FN
A	Atitlán	Amatitlán	0.7851	0.0401	2,324	55,672
B	Amatitlán	Atitlán	0.5081	0.1312	282	1,868

 Curvas ROC/PR — Experimento A

 Matrices de confusión — Experimento A

 Curvas ROC/PR — Experimento B

 Matrices de confusión — Experimento B

Un PR-AUC de 0.785 en el Experimento A no equivale a generalización satisfactoria: bajo el umbral operacional el recall cae a 4 %, es decir, el modelo deja pasar 55,672 de las zonas

positivas reales. La causa es el cambio de prevalencia entre lagos (0.064 % en Atitlán frente a 14.51 % en Amatitlán, un factor de ~227): el umbral de decisión aprendido en una distribución no se transfiere a otra con una probabilidad base tan distinta.

10. Interpretabilidad del Random Forest (Ejercicio 8)

Importancia nativa (impureza)

 Importancia nativa

Variable	Importancia
B07	0.330
B03	0.221
B08	0.149
B8A	0.145
NDWI	0.069
B02	0.041
B11	0.026
B12	0.020

Permutation importance (sobre 150,000 observaciones NO usadas para ajustar el modelo evaluado)

 Permutation importance

Variable	Caída de PR-AUC al permutar
B07	0.876
B03	0.069
NDWI	0.064

Variable	Caída de PR-AUC al permutar
B08	0.054
B8A	0.049
B02	0.032
B12	0.023
B11	0.017

SHAP (`shap.TreeExplainer`, **15,704** observaciones estratificadas por lago × clase)

 SHAP beeswarm

 SHAP bar

 SHAP dependence

Variable	SHAP medio (valor absoluto)
B07	0.2108
B03	0.0930
B8A	0.0659

Las tres técnicas coinciden en que **B07 (borde rojo, 783 nm)** domina la predicción, seguida por **B03 (verde)**. Esto es coherente con el rol del borde rojo en la detección de biomasa algal en el algoritmo CyanoLakes.

Advertencias obligatorias sobre esta interpretación:

- **SHAP no implica causalidad:** describe la contribución de cada variable a la predicción del modelo, no un mecanismo físico verificado.
- Las bandas espectrales están **fuertemente correlacionadas** entre sí; la importancia se reparte entre variables redundantes y un valor bajo no significa que una banda sea prescindible.
- La respuesta es un **proxy espectral** de clorofila-a, no una medición in situ.
- La muestra SHAP **sobrerrepresenta la clase positiva** (36–39 % frente al 1.6 % poblacional) para conservar suficientes ejemplos positivos: las magnitudes son

importancia relativa, no frecuencia esperada en el lago.

11. Mapas de probabilidad (Ejercicio 9)

Mapas descriptivos (modelo ajustado con todo el dataset)

 Probabilidad Amatitlán 2026-06-19

 Probabilidad Atitlán 2026-04-13

 Comparación entre lagos

 Evolución temporal de la predicción

Se generaron **22 GeoTIFF** de probabilidad (uno por combinación lago-fecha), en float32, EPSG:32615, con NoData, comprimidos con LZW y con tags de lago, fecha, modelo y umbral. Las fechas críticas (Amatitlán 2026-06-19, Atitlán 2026-04-13) se confirmaron desde los CSV de la Parte 1.

Advertencia metodológica central. Estos mapas se generan con un Random Forest **ajustado** con el 100 % del dataset** para producir una capa descriptiva de despliegue. **No son una validación no sesgada:** el modelo ya vio esas observaciones durante el ajuste. La evaluación** honesta del desempeño espacial es la sección siguiente.

Errores espaciales out-of-fold (evaluación no sesgada)

Cada una de las 3,756,510 observaciones se predijo **exactamente una vez**, con los mismos cinco folds espaciales del Ejercicio 6 (cero bloques compartidos, hiperparámetros fijos, sin ajuste adicional).

Métrica	Valor
PR-AUC OOF	0.9779
Recall (umbral operacional)	0.7774
Precision (umbral operacional)	0.9832
Verdaderos positivos (TP)	46,760
Falsos negativos (FN)	13,386 (535.4 ha sin aviso)

Métrica	Valor
Falsos positivos (FP)	797 (31.9 ha de inspección innecesaria)
Verdaderos negativos (TN)	3,695,567

 Errores OOF Amatitlán 2026-06-19

 Errores OOF Atitlán 2026-04-13

El **falso negativo es el error ambientalmente más grave**: una zona con floración alta que no recibe aviso. Por eso la métrica prioritaria es el Recall, complementada con F2 (que pondera el Recall por encima de la Precision).

12. Conclusiones (Ejercicio 10)

1. El **split aleatorio 70/30 es optimista**: mezcla píxeles vecinos del mismo bloque de 1 km, casi idénticos entre sí.
2. **Random Forest y XGBoost están en empate práctico** bajo validación espacial (diferencia 0.0001, menor que la desviación entre folds).
3. Existe **inestabilidad temporal marcada**: el desempeño cae de ~ 0.976 (espacial) a ~ 0.74 (temporal), con desviación de ~ 0.25 entre fechas.
4. La **transferencia entre lagos no es satisfactoria**: con umbral fijo, el recall operacional se desploma en ambas direcciones (4 % y 13 %).
5. El modelo sirve como **apoyo de cribado** dentro del dominio observado —estos dos lagos, estas fechas, este algoritmo de referencia—, no como sistema de alerta universal.
6. **No sustituye el monitoreo in situ**: no confirma presencia de cianobacterias ni toxicidad.
7. **No demuestra transferencia robusta** a otros lagos ni a fechas futuras fuera del rango observado.

13. Limitaciones

- La respuesta es un **proxy espectral** de clorofila-a, no una medición de cianobacterias ni de toxinas.
- **No hubo validación in situ** en ninguna fase del laboratorio.
- El algoritmo CyanoLakes reporta **MAPE 42.3 % y RMSE relativo 95.8 %**, calibrado para
 - Microcystis aeruginosa* sobre datos simulados.

- Dominio de calibración del NDCI: 1–60 µg/L; una parte importante de los píxeles de Atitlán queda por debajo de ese rango.
- Atitlán presenta **clorofila estimada negativa** en una fracción de sus píxeles: valores sin sentido físico, conservados para trazabilidad, no forzados a cero.
- La colección SENTINEL2_L1C **no expone máscara de nubes por píxel** (sin CLM, CLP, dataMask, SCL ni QA60).
- Solo **22 escenas** (11 fechas por lago): insuficiente para afirmar tendencias interanuales.
- **Desbalance 1:61** y fuerte concentración de los positivos (37.7 % en 5 bloques, 87.6 % en 5 fechas de la Parte 1).
- Los mapas de probabilidad descriptivos son *in-sample*; la evaluación no sesgada es la out-of-fold.

14. Recomendaciones

1. **Validar con muestreo de campo** al menos las fechas y bloques donde el modelo predice alta probabilidad, antes de usarlo para decisiones operativas.
2. **No usar el modelo entrenado en un lago para predecir en el otro** sin recalibrar el umbral con datos locales.
3. Priorizar la **validación espacial y temporal** sobre el split aleatorio al reportar desempeño esperado.
4. Ampliar la serie temporal en futuras temporadas para reducir la inestabilidad observada entre fechas.
5. Investigar una máscara de nubes por píxel (por ejemplo, migrando a una colección con SCL) para reducir ruido en las bandas de entrada.
6. Usar los mapas de error out-of-fold —no los descriptivos— para cualquier estimación de cobertura o de área afectada.

Alcance del sistema. Herramienta de **cribado** para priorizar dónde y cuándo muestrear, dentro del dominio observado (estos lagos, estas fechas, este algoritmo). No es un diagnóstico de toxicidad ni un sustituto del monitoreo in situ.